

3DGS による視点拡張と幾何教師を用いた テニスコート検出

データ生成・多タスク学習・未学習画像での定性評価

tennis-lab 技術報告 2026 年 9 月 20 日

Abstract

放送映像に偏ったコート検出器を、多様な撮影視点へ適用するための実装済みパイプラインを整理する。実動画から 3D Gaussian Splatting (3DGS) でシーンを再構成し、地面と規格コートを位置合わせして、新規視点の RGB と幾何教師を生成する。これを実画像と混合し、凍結 DINOv3 特徴に Transformer・DPT・複数の予測ヘッドを接続して学習する。指定写真 4 枚の保存推論に対し、KP 候補を LINE で選び、外れ値 KP を除外して点と線を共同最適化する。LINE との整合は改善したが、遮蔽や線の対応の曖昧さは残る。B00-B03 各 3 視点の実レンダリングと全 4 枚の推論を掲載する。

1 はじめに

テニスシーンの 3 次元再構成では、コートの規格寸法がボール・プレーヤーの位置を共通座標系に結び付ける基準になる。しかし、固定された放送視点での検出が良好でも、低い視点、横向き、見切れ、背景の変化に対応できるとは限らない。必要なのは、線が見えることと正しい規格コートへ対応付くことを分けて確かめることである。本報告は、既存の再構成・教師生成・学習を一つの手法として記述し、生成画像上の幾何整合と指定実画像上の推論を追跡可能な形で示す。

2 関連研究

TennisCourtDetector (TCD) [1] は TrackNet に近い構成で 14 点のコートキーポイント (KP) を推定し、局所的な線検出とホモグラフィで補正する。3DGS[2] は異方性 Gaussian の位置・形状・不透明度・外観を最適化し、校正カメラに対する新規視点画像を合成する。本手法ではこの画像合成を教師付きデータの視点拡張に用いる。検出器には自己教師あり視覚特徴の DINOv3[3] と、多段特徴を空間的な予測へ戻す DPT[4] を組み合わせる。Nie ら [8] は KP からの初期 H を密な線・領域の距離マップで補正し、PnLCalib[9] は点と線を用いて幾何推定を共同最適化する。本報告はこの方向を、二値 LINE と明示的な KP 除外を持つ後処理として構成する。

SfM・単眼 SLAM のドリフト。 Holynski ら [5] は、画像間の通常の点対応を越えて広がる平面・消失点を大域 SfM の制約に用い、位置・スケールの長周期ドリフトを低減した。Strasdat ら [6] は、単眼 SLAM の再訪時に相似変換の pose graph を最適化し、回転・並進に加えてスケールのずれを補正する。前者は長距離の構造制約、後者はループ閉じ込みによる整合化である。

3 手法

3.1 3DGS 再構成と規格コートへのアライメント

動画の多視点画像から SfM でカメラの内部・外部パラメータとシーンを推定し、3DGS の学習済み表現を得る。再構成座標のスケールは任意なので、規格コートの長さ 23.77 m・ダブルス幅 10.97 m を尺度とする。再構成点の RANSAC 平面推定 (図 1) と LINE 検出の地面への投影 (図 2) を使い、共通スケールと各コートの平面内位置・向きを求める。推定地面 $\mathbf{n}^\top(\mathbf{X} - \mathbf{o}) = 0$ に対し、カメラ中心 $\mathbf{C}$ 、画素からのレイ $\mathbf{d}$ の交点は

$$\mathbf{X} = \mathbf{C} + \lambda \mathbf{d}, \quad \lambda = \frac{\mathbf{n}^\top(\mathbf{o} - \mathbf{C})}{\mathbf{n}^\top \mathbf{d}} \quad (1)$$

となる。平面に平行・カメラ後方などの無効な交差は除外する。各視点の LINE 確率を共通の地面グリッドへ写像し、距離に応じた重みで集約する。その証拠に規格コートを当てはめ、残差から追加コートを探索する。当てはめ用と保留視点を分け、検出線との距離・支持量で整合性を確認する。保存結果の B00・B03 は自動受理、B01・B02 は人手調整・確認を含む。

地面推定と多視点 LINE 投影の実例 (B00)

カメラの上方向・撮影範囲・高さ分布から点群の地面候補を絞り、3点から作る平面を1,000回試す。最大20,000候補点の距離内支持数を最大化し、同数なら残差中央値の小さい仮説を選ぶ。その後、支持点のSVDによる平面再推定を3回行う。元の217,407点と保存設定 (seed 42) から再計算し、保存平面との一致を確認した。




図1 実 SfM 点群からの地面推定。(a) 元の RGB を持つ点群、(b) 高さ帯の候補 75,208 点 (橙)、(c)RANSAC + SVD 後の支持 65,325 点 (青緑) と推定平面 (赤紫)。距離しきい値は再構成座標で RANSAC 0.006、再推定 0.008。軸は確定スケールで m へ換算した。3 パネルは同じ地面周辺領域を拡大し、表示のみ 3 点に 1 点へ間引き、候補・支持点を前面に描いた。表示の切り出し・間引きは推定に影響しない。

LINE 確率 $p \geq 0.5$ の画素をレイと地面の交点へ写し、共通グリッド (約 3.58 cm) に配置する。距離 r による重み $w = 1/(1 + (r/5.01 \text{ m})^2)$ を用い、各視点・各セルで $e_v(g) = \max_{x \rightarrow g} w_v(x)p_v(x)$ 、全当てはめ視点の証拠を $E(g) = \sum_{v \in \text{fit}} e_v(g)$ とする。 E は確率ではなく重み付きの総量である。




図2 各視点の LINE から投影・集約への過程。上段は校正済み実画像と実 LINE 確率の重畳、中段は同じ地面座標への各視点の投影。下段は表示 3 視点の和、全 32 当てはめ視点の和、保存コートとの重畳。16 保留視点は集約に含めない。地面図は白が支持なし、色域共通。細線を読むよう表示のみ 3×3 セルの最大値へ縮約し、 $\gamma = 1/3$ とした。元の集約グリッドは保存値と完全一致した。当時の実画像入力・LINE 専用重み (epoch 19) の結果であり、未学習推論用の多タスク重み (epoch 17) とは区別する。

3.2 新規視点画像と教師の生成

コート中心を向く複数のカメラ軌道を設定し、3DGS から RGB をレンダリングする。規格コート点 $\mathbf{X}_j^c$ をシーンへ移す変換を $T_{s \leftarrow c}$ 、カメラ姿勢を $T_{s \leftarrow v}$ とすると、同じ視点の教師画素は

$$\tilde{\mathbf{u}}_{vj} \sim K_v [I \mid 0] T_{s \leftarrow v}^{-1} T_{s \leftarrow c} \begin{bmatrix} \mathbf{X}_j^c \\ 1 \end{bmatrix} \quad (2)$$

で求める。レンダリングと教師でカメラ・座標系を共有することが整合の要点である。保存データの v3 契約は対象コート 1 面・KP14 で、反対側の視点では近遠・左右の対応を 180 度回転の規則で揃える。画面内・前方・レンダラでの可視性を区別し、KP ヒートマップ、領域分割 (SEG)、二値 LINE、線種ごとの semantic LINE を構成する。連続した近接画像の混入を避けるため分割は軌道群単位とする。

3.3 検出器と学習目的

凍結した DINOv3 ViT-B/16 の第 3・6・9・12 ブロック特徴を利用する。最深段に幅 768・8 層・12 ヘッドの Transformer を挿入し、その空間特徴と浅い 3 段を 512 チャンネルの DPT で融合する。各密予測ヘッドは 256 チャンネル・3 残差ブロックからなり、KP、SEG、LINE、semantic LINE を出力する。別の query から姿勢を推定する 10 次元ヘッド (回転 6 次元、並進 3 次元、対数焦点距離 1 次元) も学習する。損失は

$$\mathcal{L} = \mathcal{L}_{\text{KP}} + \mathcal{L}_{\text{SEG}} + \mathcal{L}_{\text{LINE}} + \mathcal{L}_{\text{SLINE}} + \mathcal{L}_{\text{pose}}^{\text{synth}} \quad (3)$$

であり、KP は focal BCE ($\gamma = 2$)、領域・線種は CE + Dice、LINE は正例重み 8 の BCE + Dice を用いる。姿勢は合成画像だけに教師を持ち、並進 MSE・回転の測地角・対数焦点距離 MSE を等重みで加える。KP と姿勢の整合損失はこの重みでは無効である。各バッチを合成 4 枚 + TCD 実画像 4 枚とし、短辺 256/320/384/448/512 の多解像度、色変動・ぼかして学習した。AdamW、学習率 10^{-4} 、weight decay 1、warmup 3 epoch を用いた保存重み (epoch 17、29,844 step) を固定する。

3.4 外れ値を除外する KP・LINE 共同推定

候補と採用点。KP の sigmoid ピーク値 s_i で順位付けした PROSAC[7] に、最下位点の順位が小さい順で非退化な 4 点組を列挙する候補 (最大 1,001 組) を追加する。二値 LINE は線種を区別しないため、KP の意味対応を保持する。外れ値を前提とし、再投影誤差 $r_i = \|\pi(HX_i) - q_i\|$ と観測 KP から LINE 中心への距離 $d_L(q_i)$ がともに τ 以下、かつ $s_i \geq 0.05$ の点だけを選ぶ。 $s_i/(1 + (r_i/\tau)^2)$ の上位最大 8 点を S とし、4 点以上の非退化な支持を要求する。**除外点は KP 損失に含めない。**各最適化中は S を固定し、終了後にゲートを更新して再最適化する。各距離場で最大 4 回まで更新し、集合が安定しなければ失敗とする。上限 8 点と閾値は全画像で共用するヒューリスティックである。

共同目的。確率 0.5 以上の LINE の内部距離変換から稜線を抽出する。規格コートの主要 9 線を画像内にクリップし、各線 40 点から稜線までの距離を線ごとに平均する。逆方向には固定した稜線観測から投影線分までの距離を LINE 確率で重み付けする。

$$E(H; S) = 0.25 \sum_{i \in S} w_i (r_i/\tau)^2 + E_{\text{line}}^{\rightarrow} + E_{\text{line}}^{\leftarrow} + 0.1 E_{\text{dir}}. \quad (4)$$

$w_i \propto 0.5 + 0.5s_i$ は和を 1 とし、信頼度を正解確率とは扱わない。LINE 距離は τ で正規化して 4τ で打ち切り、方向項は近傍稜線の主方向との不一致を、方向の確かさと近接度で重み付けする。投影が異なる上位最大 6 候補の 8 自由度の H を平滑化距離場、元の距離場の順で最適化する。双方向の支持不足、射影極・縮退、異なる候補間の僅差は失敗とし、旧 H への代替は行わない。

4 実験設定と評価範囲

4.1 ウェブ画像による評価

ウェブ上で取得したテニスコート写真 4 枚を、TCD の実画像データセットと B00-B03 の 3DGS 合成データセットのいずれにも含まれない評価画像として用いた。4 枚を A-D に対応付け、すべて推論・掲載した (図 5、6)。TCD の 8,841 枚と B00-B03 の 8,415 レンダリングとの照合では、ファイル SHA-256 および向き補正後 RGB の完全一致は 0 件だった。

4.2 比較条件と表示方法

TCD は公開重みと BGR 入力 640×360 、しきい値 $170/255$ の公式ピーク抽出・局所補正を用いる。本モデルは RGB・ImageNet 正規化、短辺 $512 \cdot 16$ 画素整列で推論し、KP をチャンネルごとに 1 点抽出する。本モデルの H は保存 KP・スコア・LINE から CPU で再計算し、 τ は原画像対角長の 0.5% で全 4 枚共通とした。OpenCV 5.0.0 の PROSAC (種 42、非並列) と SciPy 信頼領域法 ($\text{max_nfev}=70$) を用い、稜線観測は最大 768 点とする。双方向の線支持率 0.55 以上、縦・横各 2 本以上の支持を要求する。全設定・採用履歴・除外理由と 3 段階の結果を同梱する。TCD は公式の 12 組候補選択を 1280×720 座標で行い、 argmax による補助結果も併記する。

推論は CPU、EXIF 補正は共通、追加クロップなしとした。本モデルの LINE は確率 0.5 以上を白とする二値マスク・原画像への直接重畳・確率マップの 3 形式で示す。確率マップは共通の $[0, 1]$ 色域を使う。





図 3 同一の保存推論を使う 3 段階の幾何復元。線は各段階の H、丸点は採用 KP、灰 × は不採用 KP である。最適化した候補のうち最良を選ぶため、中央の最良初期候補が必ず右の初期値とは限らない。定量的な予測間整合は表 2 に示す。


5 結果

5.1 3DGS レンダリングと保存アライメント


B00 : 2 面 / 自動受理



B01 : 3 面 / 人手確認



B02 : 1 面 / 人手確認



B03 : 1 面 / 自動受理




図 4 実際の 3DGS 新規視点レンダリングに、保存済み 3D コートを同じカメラで再投影した 12 例。各行は異なる 3 軌道群から、線構造と視点差を確認できる例を選んだ。水色・橙・桃はシーン内のコートを識別する。全コートの地面線を描き、ネット等による遮蔽マスクは適用していない。ぼけ・浮遊物・見切れも元レンダリングのまま残した。

	train	val	test	軌道群	保留視点の整合 RMS [m]
B00	1,718	220	238	35	0.105 / 0.130
B01	1,559	295	198	26	0.032 / 0.233 / 0.036*
B02	1,648	194	252	40	0.091*
B03	1,669	226	198	40	0.109
計	6,594	935	886	141	

表 1 保存済み生成データの内訳とコートごとの整合値。RMS は検出された線との残差。* は人手調整後の値。

図 4 の 3D 座標・カメラによる再投影は、保存された 2D 教師と照合した。B00・B03 の自動当てはめは各 32 視点、保留は各 16 視点である。

5.2 指定実画像への推論：低視点・斜視


橙＝TCD、水色＝本モデル。丸点は採用 KP、灰×は不採用（外れ値・LINE 支持不足・点数上限）、線は H による規格コート。TCD は局所補正点のみ。LINE 欄は直接の密予測である。

A : ennai011_1.jpg / 1,000×667



共同推定は 7 点を採用し、KP のみで過大に広がった手前の外周を LINE に合わせる。外周・内側線の整合は改善した。

B : images (1).jpg / 638×480



共同推定は 5 点を採用して見切れを含む線へ合わせる。各方向の支持率は単独には単調改善しない（表 2）。信頼度 Top-4 は共線で、4 点固定では解けない。

図 5 指定写真 A・B の実推論。上段は KP と H、下段は LINE。マスクは白が $p \geq 0.5$ 。確率マップは黒 0～黄白 1 の共通色域。全パネルは縦横比を保ち、画像全域を示す。

	A	B	C	D
TCD 公式：検出点数 / 14	3	1	0	1
TCD 公式：H 生成	不可	不可	不可	不可
TCD argmax：H 生成	可	不可	不可	不可
本モデル：KP+LINE H 生成	可	可	可	可
本モデル：KP 損失の採用点 / 14	7	5	4	8
本モデル：採用 KP 残差 RMS [px]	2.80	1.81	1.72	1.46
KP のみ：線支持率 [%]	73.9/81.8	61.9/80.1	53.3/86.1	90.6/91.6
LINE で候補選択：線支持率 [%]	94.4/97.9	86.9/99.9	54.2/75.2	98.9/96.6
KP+LINE 共同最適化：線支持率 [%]	99.4/99.8	83.9/100.0	66.1/98.6	99.4/96.8

表 2 後処理の比較。線支持率は距離 τ 以内の順方向／逆方向の割合（線ごと／確率による重み付け）。

5.3 指定実画像への推論：人物・観客席を含む場面

C : images (2).jpg / 547×365

入力写真



本モデル：LINE 二値マスク



TCD : 局所補正 KP (H なし)




本モデル：LINE 重畳 $p \geq 0.5$



本モデル：KP + LINE H



本モデル：LINE 確率 [0, 1]




LINE には人物周辺や奥側で途切れがある。共同推定は 4 点を採用し、検出された線の大半を説明する一方、順方向支持率は 66.1% に留まる。TCD 公式は 0 点で H なし。

D : images.jpg / 678×452

入力写真



本モデル：LINE 二値マスク



TCD : 局所補正 KP (H なし)




本モデル：LINE 重畳 $p \geq 0.5$



本モデル：KP + LINE H



本モデル：LINE 確率 [0, 1]



共同推定は 8 点を採用し、KP のみで小さく右寄りだった配置を、俯瞰コートの外周・内側線へ近付ける。画面下の小さな LINE 反応は規格コートで説明できず、打ち切り距離項で影響を制限する。TCD 公式は 1 点で H なし。

図 6 指定写真 C・D の実推論。表示条件は図 5 と共通。

6 課題点

6.1 SfM のドリフトと幾何教師への影響

SfM には、長い撮影区間で位置・姿勢・スケールの誤差が累積するドリフトの問題がある [5]。再構成の変形は 3DGS の外観と幾何教師の整合を損なうため、保存教師との再投影一致だけでは十分でない。そこで **B00-B03** すべての実 SfM 点と観測トラックを読み、地面の再構成高さを同じ条件で比較した (図 7、表 3)。

対象は保存コートの内側、保存アライメントの共通平面から ± 30 cm 以内、SfM 再投影誤差 1 px 以下の点である。登録済み画像を撮影順に二等分し、全観測が前半か後半に収まるトラックだけを使う。未登録画像は補間しない。0.5 m 格子で両区間に各 5 点以上を持つセルについて、高さ中央値の差 (後半 - 前半) を求める。同一特徴点の再推定比較ではなく、同一セル内の異なる点群による診断である。従来の 4 区間比較は共通セルが B00 で 33、B01-B03 では 0 だったため、全シーンを同じ 2 区間比較に統一した。4 区間診断の未成立も証拠データに残す。




図 7 全 4 シーンの実点群による時間依存の地面高さの不整合。元 RGB を持つ地面点群と保存コート上に、比較可能な全 0.5 m セルを描く。色は後半 - 前半の高さ差で、全シーン共通の ± 20 cm 色域。 n はセル数、軸は保存アライメントで m へ換算した。点群の表示のみ 3 点に 1 点へ間引き、数値の集計には間引きを適用しない。

	SfM 画像	SfM 点	共通セル	中央値 [cm]	四分位範囲 [cm]	1 m 格子 [cm] (セル)
B00	491	217,407	617	+0.88	[-0.52, +2.22]	+0.75 (371)
B01	266	109,717	246	+0.09	[-0.40, +0.56]	+0.00 (218)
B02	157	56,620	69	-1.38	[-8.01, +0.59]	-1.67 (92)
B03	153	44,521	6	+1.55	[-1.19, +2.84]	+0.56 (22)

表 3 同じセルの前半・後半差の分布。右端は 1 m 格子での感度確認 (中央値・共通セル数)。地面基準には保存アライメントを使い、B01・B02 は人手調整を含む。

B00 には小さな正の偏り、B02 には負側に広がる不整合がある一方、B01 の中央値はほぼ 0 である。B03 は 6 セルと少なく、1 m 格子で中央値が +1.55 から +0.56 cm へ変わるため、推定は不安定である。高さ差には SfM の時変な変形に加え、セル内の地面の凹凸や特徴点・三角測量の誤差が混在する。一つの相似変換でコートをアライメントしても、区間ごとに異なる変形は取り除けない。今後は SfM 段階の構造制約 [5] や再訪時の整合化 [6] を検討し、独立な地面基準で幾何教師の品質を確かめる必要がある。

6.2 4 シーンに限られる多様性と汎化性能の不足

合成側は B00-B03 の 4 シーンのみで、8,415 枚の視点拡張は会場・路面・照明の多様性を増やさない。4 シーンが独立した 4 会場とも限らず、同一シーン内分割のため未知会場への汎化は未評価である。共同推定も誤った KP・LINE を必ず補正できず、写真 4 枚に GT がいないため精度は未確定である。今後は会場分離の GT 付き集合で、実写のみ/合成混合と後処理を比較する。

参考文献

- [1] yastrebkv. [TennisCourtDetector](#). 公開コード・重み、コード版 e5cd4f1 (2026-09-18 参照) .
- [2] B. Kerbl, G. Kopanas, T. Leimkühler, G. Drettakis. [3D Gaussian Splatting for Real-Time Radiance Field Rendering](#). ACM TOG 42(4), 2023.
- [3] O. Siméoni et al. [DINOv3](#). arXiv:2508.10104, 2025.
- [4] R. Ranftl, A. Bochkovskiy, V. Koltun. [Vision Transformers for Dense Prediction](#). ICCV, 2021.
- [5] A. Holynski, D. Geraghty, J.-M. Frahm, C. Sweeney, R. Szeliski. [Reducing Drift in Structure From Motion Using Extended Features](#). 3DV, pp. 51-60, 2020.
- [6] H. Strasdat, J. M. M. Montiel, A. J. Davison. [Scale Drift-Aware Large Scale Monocular SLAM](#). RSS, 2010.
- [7] O. Chum, J. Matas. [Matching with PROSAC - Progressive Sample Consensus](#). CVPR, 2005.
- [8] X. Nie et al. [A Robust and Efficient Framework for Sports-Field Registration](#). WACV, 2021.
- [9] M. Gutiérrez-Pérez, A. Agudo. [PnLCalib: Sports Field Registration via Points and Lines Optimization](#). CVIU, 2026.